

antcorpgen

LLM não gera artigos completos

↳ Abstracts

Relatórios longos também

Palavras absolutamente necessárias, auto-suficientes
environment ou 'climate change'

aquilo que você não detecta pode ~~ser~~ conter muita coisa → falsos ~~positivos~~ negativos

encontrar	verdadeiros positivos
aumentar	
reduzir	falso positivos negativos

 : Exemplo → encontro de Brasília

Mark Davis : Coronavirus Corpus | O pesquisador tem credenciais
↳ conhecimento dele

Glossário sobre Climate Change

Google Scholar: digita os termos

↳ os primeiros → detecta falso positivos

abrir alguns artigos e verificar as key words

3000 citações

aqueles que citaram → selecionam

claude	GPT	Gemini	Grok
50	50	50	50

Tamanho do Corpus final

relatório 200

reportagem 200

abstracts 200

stories 200

200

1000 humanos 1000 de máquina | 2000

Os ~~estratos~~ são organizados por ~~organização~~ ^{atores sociais}, não importa o registro
↳ componentes do corpus

Na rede social

video registro
postagem registro

Sampling unit

não significa que a escrita acadêmica

↳ segmento

texto inteiro → segmento de texto

sempre importante: introdução e desatios

chegar

ator social governo - relatório

↳ registro do ator governamental

ONU: Sampling unit

Montar um corpus balanceado → encontrar segmentos que permitam chegar a ~~200~~ 200

ONG $\div 4$ LLM

$(66) + (67) + (67) = 200$ } LLMs

$50 + 50 + 50 + 50 = 200$

• delimitadores de seção: $\begin{cases} \text{begin} \{section\} \\ \text{end} \{section\} \end{cases}$

Discrepância muito grande

1. prompt simples: gere um texto (tema)

suas
próprias palavras

2. extrair do texto info: resumo (outline) que não seja idêntico
registro até supragovernamental ONU

um ou outro

prompt detalhado → explica os detalhes

↳ contexto de
produção do texto

System prompt ⇒ Persona relevante para o texto
User prompt ⇒ Task

critério para escolher este tipo de prompt

↳ Não omitir info para ~~dar reprodução~~

reconstruir o contexto de produção